# 20 NEWS GROUP CLASSIFICATION

Anonella Zaccaria Marco Savino 848647 793516

### **PIPELINE**

#### 20 NEWSGROUPS DATASET PREPROCESSING · Conversione testo in minuscolo Eliminazione indirizzi mail Eliminazione dei numeri Eliminazione caratteri di punteggiatura · Rimozione parole composte da una e due lettere · Sistemazione degli spazi creati con le precedenti operazioni Tokenizzazione · Rimozione stop words Stemming Stemming Stemming Lemmatization (Porter) (Snowball) (Lancaster) TRAIN SET (60%) TEST SET (40%) TF TF TF • TF TF-IDF UNIGRAM TF-IDF UNIGRAM TF-IDF UNIGRAM TF-IDF UNIGRAM TF-IDF UNI+BIGRAM . TF-IDF UNI+BIGRAM TF-IDF UNI+BIGRAM TF-IDF UNI+BIGRAM TEXT REPRESENTATION NAIVE BAYES SVM RANDOM FOREST XGBOOST CLASSIFICATION

# DATASET 20 NEWSGROUPS

### 19997 documenti divisi in 20 newsgroups:

- 1. alt.atheism
- 2. comp.graphics
- 3. comp.os.ms-windows.misc
- 4. comp.sys.ibm.pc.hardware
- 5. comp.sys.mac.hardware
- 6. comp.windows.x
- 7. misc.forsale
- 8. rec.autos
- 9. rec.motorcycles
- 10.rec.sport.baseball

- 11. rec.sport.hockey
- 12. sci. crypt
- 13. sci.electronics
- 14. sci. med
- 15. sci. space
- 16. soc.religion.christian
- 17. talk.politics.guns
- 18. talk.politics.mideast
- 19. talk.politics.misc
- 20. talk.religion.misc

# PREPROCESSING

- Conversione testo in minuscolo
- Eliminazione indirizzi mail
- Eliminazione dei numeri
- Eliminazione caratteri di punteggiatura
- Rimozione parole composte da una e due lettere
- Sistemazione degli spazi creati con le precedenti operazioni
- Tokenizzazione
- Rimozione Stop Words
- Lemmatization
- Stemming: Porter, Snowball, Lancaster

Dataset diviso in Training set (60%) e Test set (40%)

# TEXT REPRESENTATION

- Term Frequency (TF): la Term Frequency tft,d del termine t nel doumento d è definito come il numero di volte che t si verifica in d
- Term Frequency-Inverse Document Frequency (TF-IDF): il peso tf-idf di un termine è il prodotto del suo peso tf e del suo peso idf
  - Unigram
  - Unigram + Bigram

### Matrici costruite per:

- Dati lemmatizzati
- Dati stemmatizzati (Porter)
- Dati stemmatizzati (Snowball)
- Dati stemmatizzati (Lancaster)

→ 24 Matrici (12 Train + 12 Test)

# TEXT CLASSIFICATION

- Multinomial NB
- SVM
- Random Forest
- XGBOOST

## MULTINOMIAL NAIVE BAYES

	TRAIN (cross validation)		TEST	
	Accuracy	Time	Accuracy	Time
TF + LEM	0.86	383 ms	0.87	127 ms
TF + STEM (Porter)	0.85	351 ms	0.86	106 ms
TF + STEM (Snowball)	0.85	345 ms	0.86	113 ms
TF + STEM (Lancaster)	0.85	306 ms	0.85	111 ms
TF-IDF + LEM	0.86	252 ms	0.87	77.6 ms
TF-IDF + STEM (Porter)	0.85	215 ms	0.86	77.7 ms
TF-IDF + STEM (Snowball)	0.85	223 ms	0.86	77.3 ms
TF-IDF + STEM (Lancaster)	0.85	222 ms	0.86	76.6 ms
TF-IDF (bigram) + LEM	0.86	262 ms	0.87	101 ms
TF-IDF (bigram) + STEM (Porter)	0.86	267 ms	0.87	88.7 ms
TF-IDF (bigram) + STEM (Snowball)	0.86	261 ms	0.87	89.8 ms
TF-IDF (bigram) + STEM (Lancaster)	0.86	247 ms	0.86	88.2 ms

# SUPPORT VECTOR MACHINE (SVM)

	TRAIN (cross validation)		TEST	
	Accuracy	Time	Accuracy	Time
TF + LEM	0.75	9 min 10 s	0.78	3 min 29 s
TF + STEM (Porter)	0.75	8 min 52 s	0.78	3 min 28 s
TF + STEM (Snowball)	0.75	8 min 55 s	0.78	3 min 27 s
TF + STEM (Lancaster)	0.74	8 min 37 s	0.77	3 min 20 s
TF-IDF + LEM	0.89	12 min 40 s	0.90	4 min 35 s
TF-IDF + STEM (Porter)	0.89	12 min 40 s	0.90	4 min 34 s
TF-IDF + STEM (Snowball)	0.89	12 min 27 s	0.90	4 min 29 s
TF-IDF + STEM (Lancaster)	0.88	12 min 26 s	0.89	4 min 18 s
TF-IDF (bigram) + LEM	0.89	14 min 12 s	0.90	5 min 4 s
TF-IDF (bigram) + STEM (Porter)	0.89	14 min 34 s	0.90	5 min 10 s
TF-IDF (bigram) + STEM (Snowball)	0.89	14 min 5 s	0.90	4 min 59 s
TF-IDF (bigram) + STEM (Lancaster)	0.89	13 min 44 s	0.89	5 min

## RANDOM FOREST

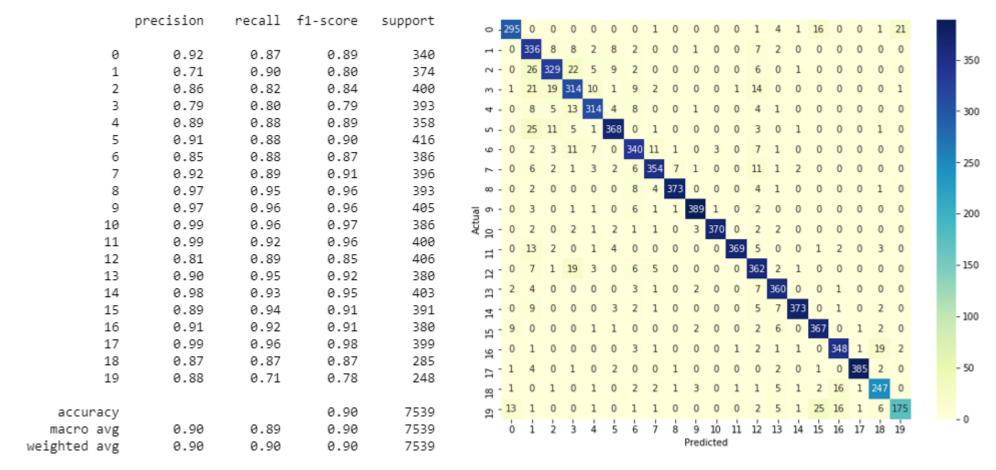
	TRAIN (cross validation)		TEST	
	Accuracy	Time	Accuracy	Time
TF + LEM	0.83	2 min 46 s	0.84	32.6 s
TF + STEM (Porter)	0.82	2 min 25 s	0.84	30.6 s
TF + STEM (Snowball)	0.82	2 min 25 s	0.84	29.9 s
TF + STEM (Lancaster)	0.81	2 min 16 s	0.83	29.4 s
TF-IDF + LEM	0.82	1 min 31 s	0.83	23.8 s
TF-IDF + STEM (Porter)	0.81	1 min 33 s	0.83	23.7 s
TF-IDF + STEM (Snowball)	0.81	1 min 34 s	0.83	23.7 s
TF-IDF + STEM (Lancaster)	0.80	1 min 40 s	0.82	24.3 s
TF-IDF (bigram) + LEM	0.82	1 min 31 s	0.83	24.5 s
TF-IDF (bigram) + STEM (Porter)	0.81	1 min 31 s	0.83	24.8 s
TF-IDF (bigram) + STEM (Snowball)	0.82	1 min 31 s	0.83	24.4 s
TF-IDF (bigram) + STEM (Lancaster)	0.81	1 min 33 s	0.82	24.9 s

# XGBOOST

	TRAIN (cross validation)		TEST	
	Accuracy	Time	Accuracy	Time
TF + LEM	0.80	15 min 44 s	0.80	3 min 20 s
TF + STEM (Porter)	0.80	13 min 33 s	0.79	2 min 58 s
TF + STEM (Snowball)	0.79	13 min 24 s	0.79	2 min 56 s
TF + STEM (Lancaster)	0.78	12 min 10 s	0.79	2 min 40 s
TF-IDF + LEM	0.79	13 min 33 s	0.79	3 min 20 s
TF-IDF + STEM (Porter)	0.79	13 min 58 s	0.79	3 min 27 s
TF-IDF + STEM (Snowball)	0.79	14 min 14 s	0.79	3 min 30 s
TF-IDF + STEM (Lancaster)	0.78	14 min 25 s	0.78	3 min 32 s
TF-IDF (bigram) + LEM	0.80	15 min 32 s	0.80	3 min 51 s
TF-IDF (bigram) + STEM (Porter)	0.80	15 min 45 s	0.80	3 min 49 s
TF-IDF (bigram) + STEM (Snowball)	0.80	15 min 30 s	0.80	3 min 49 s
TF-IDF (bigram) + STEM (Lancaster)	0.79	15 min 42 s	0.79	3 min 53 s

### CONCLUSIONI

Il modello migliore in termini di *Recall, Precision* ed *F1-score* risulta essere *Support Vector Machine* nelle rappresentazioni tf-idf



# GRAZIE PER L'ATTENZIONE